LABORATUVAR 7 · ISP BANBURY · Kauçuk Mikseri

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad **Berfin Aslan** | Grup **Gece B** | Tarih **06.11.2026**

> **Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: *Banbury'ye* **YZ'li kalite kontrolü eklenmesi planlanıyor** *(föydeki planlı özellik): kamera ve proses verisinden (sıcaklık, süre, tork) model karışımı OK / RED sınıflandırır; sonuç reçete parametresini ve boşaltma kararını etkiler. Proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera + sensör → YZ Modeli → OK / RED → Parametre (süre · ram basıncı) → Mikser (PLC)

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu karışıma OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   YZ'nin OK'ı tek başına geçerli sayılmaz. PLC'deki sabit sıcaklık / süre / tork limitleri YZ'den bağımsız çalışır ve OK bunları aşamaz. İkinci kontrol: laboratuvar numune testi (örnekleme). İnsan onayı: kritik partilerde kalite operatörü boşaltma onayı verir. Kapak kilidi, acil stop ve ram kilidi YZ'ye hiç bağlı değildir.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Fark etme: görüntü donmuş mu / zaman damgası tutuyor mu, kamera ile sıcaklık ve tork sensörü çelişiyor mu (kamera "normal", sıcaklık yüksek), veri eğitim dağılımının dışında mı, kamera bağlantı sağlığı (heartbeat) sürüyor mu.

   Şüpheli girdide: YZ kararı yok sayılır, alarm ve log üretilir, parti karantinaya alınır, sistem son iyi reçete ve sabit limitlerle manuel kontrole döner. YZ ancak girdi doğrulanınca geri alınır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik, saha verisiyle ayarlanır; eğitim örneği: %90. Altında otomatik karar yok: parti işaretlenir ve **insana sorulur**. Üst üste birkaç düşük sonuçta YZ devre dışı kalır, **fallback** olarak sabit reçete ve elle kalite kontrol gelir. Mikseri karışımın ortasında durdurmam; durdurmayı yalnızca PLC'nin fiziksel limitleri veya emniyet zinciri yapar.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	PLC'de sabit limitler + kalite operatörü onayı; OK limitleri aşamaz. **(second check + human override)**
Girdi manipüle edildi	Girdi doğrulama ve sensör çapraz kontrolü; şüphede YZ devre dışı, parti karantina, son iyi reçete. **(monitoring + fail-safe + fallback)**
Confidence düştü	Eşik altında otomatik karar yok; insana sor, tekrarlarsa elle kontrol. **(confidence threshold + human override + fallback)**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.